

باسمه تعالی

فاطمه اختیاری

موضوع:

روش‌های بهینه‌سازی حافظه در چت‌بات‌ها

چرا حافظه در چت بات ها مهم است؟

بدون حافظه، چت بات ها تعاملات گذشته را خیلی زود فراموش می کنند که منجر به یک تجربه کاربری ناخوشایند می شود زیرا نمی توانند به گفتار قبلی خود تکیه کنند. از سوی دیگر، ذخیره نامحدود هر پیام و انتقال آن ها به مدل ناکارآمد است. هدف، یافتن تعادلی بین حفظ متون مفید^۱ و بهینه سازی استفاده از حافظه است [۱].

مشکلات رویکردهای سنتی

۱. وارد کردن داده های غیر ضروری: پرهزینه و کند کننده پردازش.
۲. پنجره های حافظه با طول ثابت: متن پس از یک نقطه خاص قطع می شود و اطلاعات مهم از دست می روند.
۳. بازیابی مبتنی بر جاسازی: خوب کار می کند، اما باز هم پرهزینه است.

راه حل ها:

استراتژی های سطح سیستم^۲: چه چیزهایی را باید به خاطر سپرد و چگونه؟

۱ – context window

این روش ساده ترین رویکرد محسوب می شود: کافی است یک بافر مثلاً deque در پایتون نگهداری کنید که با افزوده شدن پیام های جدید، به طور خودکار قدیمی ترین ها را حذف کند. برای نمونه، OpenAI Agents SDK ابزارهایی مانند TrimmingSession را ارائه می دهد که تنها N نوبت آخر مکالمه را حفظ می کند. این روش نقطه شروع مناسبی است، به ویژه برای مکالمات وظیفه محور که تنها آخرین مراحل تعامل اهمیت دارند [۲].

۲ – Summarization

در مواجهه با مکالمات بسیار طولانی، می توان از یک مدل زبانی بزرگ (LLM) برای تولید خلاصه ای از تعاملات قبلی استفاده کرد و سپس آن را جایگزین تاریخچه خام در درخواست های بعدی نمود. این رویکرد برای حفظ جملات در بازه های طولانی بسیار مؤثر است، اما لازم است بر پدیده «انحراف خلاصه»^۳ موقعیتی که طی آن برخی جزئیات به درستی منتقل نشده یا به کلی از دست می روند، نظارت داشت. برای کاهش این اثر، می توان پس از هر رویداد مهم، خلاصه را به تدریج به روزرسانی کرد [۲].

۳ – Semantic Retrieval (Memory as a Searchable Database)

این رویکرد با حافظه مانند یک آرشیو قابل جستجو رفتار می کند. هر پیام به یک برداری عددی تبدیل شده و در یک پایگاه داده برداری (مانند ChromaDB، Pinecone یا Elasticsearch) ذخیره می شود. هنگامی که یک پرس و جوی جدید وارد می شود، سیستم آن را به یک

¹ useful context

² System-Level Strategies

³ summary drift


بردار تبدیل کرده و پیام‌های گذشته با بیشترین شباهت معنایی را برای دادن به پرامپت بازیابی می‌کند. این روش برای استخراج جزئیات بسیار خاص از بخش‌های فراموش‌شده یک مکالمه قدرتمند است، اما نیاز به مدیریت زیرساخت پایگاه داده خارجی دارد [۳].

۴- رویکرد ترکیبی حافظه بلندمدت و کوتاه‌مدت [۱]:

پیام‌های اخیر را در حافظه کوتاه‌مدت^۴ نگه می‌دارد.

پیام‌های قدیمی‌تر را به نسخه خلاصه‌شده^۵ تبدیل می‌کند.

از یک مدل خلاصه‌سازی برای مختصر نگه‌داشتن حافظه بلندمدت استفاده می‌کند.



Summarization Models for Efficient Memory

لینک‌های مورد مطالعه

[1] https://medium.com/@amirmahdi_abtl/building-a-memory-efficient-rag-chatbot-new-long-short-term-memory-approach-c3364e21b117

[2] https://developers.openai.com/cookbook/examples/agents_sdk/session_memory?utm_source=tldrai

[3] <https://arxiv.org/html/2511.12712v1>

⁴ pending tex

⁵ summary